


Aula: Introdução ao Big Data

Professora Kadidja Valéria | Ciência de Dados
e Aprendizagem de Máquina

Sistemas de Informação (7º Semestre)

Blackboard



Ambiente virtual
de aprendizagem
do curso.



Acesso a conteúdos,
atividades, avisos e
materiais.

Responsabilidade do estudante:

- ✓ Acessar sempre
- ✓ Acompanhar prazos
- ✓ Entregar atividades

Avaliações/Frequência/Aprovação

$$A1 + A2 = NF$$

Avaliação
Regimental: 5,0

Avaliação
Docente: 5,0

Nota Final



Frequência Mínima Obrigatória.

Aprovação exige $NF \geq 6,0$.

Se $NF < 6,0$ (e $A1$ ou $A2 \geq 1,0$) → AF (Avaliação Final: 5,0). A AF substitui a menor nota.

Responsabilidade do estudante: Manter frequência, cumprir prazos e acompanhar notas.

O que é Big Data?

Dados estão em todos os lugares. Mas o que acontece quando temos dados demais?



Objetivo da aula: Entender por que precisamos de novas formas de armazenar e processar dados.

Vivemos em um mundo de dados

Todos os dias produzimos dados quando:

usamos o celular

fazemos pesquisas

assistimos vídeos

compramos

usamos redes sociais

utilizamos aplicativos

usamos cartões de crédito

Pergunta **para a turma:**



**Quanto dados vocês
acacham que uma
empresa como essas
precisa processar po?**

Quando os dados ficam grandes demais?



100 clientes



Um computador comum resolve.



10 milhões de clientes

Milhões de compras → acessos → registros



1 bilhão de registros




Será que um único computador consegue processar tudo facilmente?

Afinal, o que é Big Data?

Conjunto de **tecnologias e estratégias utilizadas para armazenar, processar e analisar dados em grande escala.**



Não significa apenas 'ter muitos dados'.



Os 5 Vs do Big Data

 Volume	 Velocidade	 Variedade	 Veracidade	 Valor
Quantidade. Exige maior armazenamento e processamento.	Rapidez da geração. Dados chegam por segundo, milissegundo ou continuamente (Ex: transações bancárias).	Formatos. Tabelas, textos, imagens, vídeos, áudios, GPS, JSON.	Qualidade e Confiabilidade. Contém erros, duplicações, valores ausentes. Atenção: Dados ruins = análises/modelos ruins.	Utilidade real dos dados.


O problema



Dataset = 5 TB




Computador = 16 GB de RAM



Como processar os dados? Comprar um computador gigante?
Não. Existe outra ideia: Dividir o trabalho.

Computação distribuída

Em vez de uma máquina:




Podemos usar várias:




**Várias máquinas
trabalhando juntas.**

Cluster, nós e particionamento



Big Data + Ciência de Dados + ML



Atividade: o desafio dos 5 bilhões

Cenário

Uma empresa possui:

5 bilhões
de compras.

(Cada registro contém os
detalhes da compra).

A Missão

1. Qual cidade vende mais?
2. Qual produto vende mais?
3. Qual é o faturamento total?
4. Qual é o valor médio das compras?



O Problema

O computador disponível
possui apenas

**16 GB de
RAM.**

Como vocês resolveriam
esse problema?

Atividade em grupos



Formem grupos de **3–4 alunos**.



Vocês têm **10 minutos**.

Desenhem uma solução

- Uma máquina ou várias?

- Como dividir os dados?

- O que cada máquina faria?

- Como juntar os resultados?



Desafio extra: Uma das máquinas parou de funcionar. O que deveria acontecer?

O que levamos da aula?

Conceito: Trabalhar com dados em grande escala (Os 5 Vs:     ).



Para finalizar:

- 1 Em 3 frases, explique o que é Big Data e por que ele é importante para Ciência de Dados e Machine Learning.
- 2 Abrir um repositório no GitHub para a disciplina e registrar a resposta. (Informe a fonte de pesquisa).