

PYTHON PARA CIÊNCIA DE DADOS

Manipulação de dados tabulares com Pandas: Da tabela bruta à decisão de negócios.

Código correto + interpretação do resultado

HOJE



Compreender

Explicar Pandas, Series, DataFrame e a lógica dos dados tabulares.

Manipular

Carregar, inspecionar, selecionar, filtrar e transformar dados.

Interpretar

Resumir resultados e comunicar uma descoberta útil para decisão.

O Problema de Negócio

A coordenação de TI precisa descobrir:
Onde estão os gargalos?
Quais registros exigem atenção?
O atendimento está cumprindo o SLA?

18

Chamados
(Linhas)

10

Variáveis
(Colunas)


4

Dados Ausentes
(2 Tempo + 2 Satisfação)

120h


Alerta Crítico
(Possível Outlier)

SERIES (1D) – Estrutura unidimensional.



```
df['setor']
```

DATAFRAME (2D) – Estrutura bidimensional.



```
df[['setor']]
```

Por que dois colchetes? Eles forçam a estrutura tabular (DataFrame).

```
pd.DataFrame({'id': ['CH1'],  
             'setor': ['TI']})
```



id	setor
CH1	TI

```
pd.read_csv('chamados.csv')
```



PREVER → EXECUTAR → INTERPRETAR

Primeiro verifique a leitura. Depois, investigue a estrutura.

head()

Como os dados começam?

tail()

Como os dados terminam?

shape

Quantas linhas e colunas?

(Atenção: atributo, sem parênteses)

columns

Quais variáveis existem?

info()

Tipos de dados e valores nulos?

describe()

Qual a distribuição dos números?

UDF Analytical Console

ESTRUTURA

18 × 10

18 linhas × 10 colunas.
Variáveis numéricas e
categóricas.

COMPLETUDE

16 / 18

16 registros completos.
Faltam 2 tempos de
resolução e 2 índices de
satisfação.

DISTRIBUIÇÃO

120 h

Máximo detectado de
120h. Muito acima do
padrão da maioria da
base.

ALERTA DE NEGÓCIO: Outlier ≠ erro automático. Investigue a origem, o contexto e o impacto no mundo real antes de remover qualquer dado (ex: o chamado de 120h).

O Quê Mostrar - Colunas

```
df[['id_chamado', 'setor']]
```

Escolhe as variáveis.

Onde Buscar - Linhas

loc

Usa RÓTULOS (nomes).
Inclui o limite final.

```
df.loc[0:2, ['id_chamado', 'setor']]
```

iloc

Usa POSIÇÕES (índices numéricos).
Exclui o limite final.

```
df.iloc[0:3, 0:2]
```

Filtros respondem a condições.

```
df[df['prioridade'] == 'Alta']
```


Apenas chamados com alta prioridade.

```
df[(df['prioridade'] == 'Alta') &  
   (df['status'] == 'Resolvido')]
```

& = E, | = OU. Sempre isole as comparações com parênteses!

```
df[df['categoria'].isin(['Acesso', 'Rede'])]
```

Verifica se a categoria pertence à lista especificada.



Engenharia de Variáveis: Uma nova coluna representa uma nova lente analítica para o negócio.

```
df.groupby('categoria')['tempo_resolucao_horas'].mean()
```

Contar Frequências

```
value_counts()
```

Métricas Globais

```
mean(), min(), max()
```

```
value_counts()
```

```
mean(), min(), max()
```

1. Dividir (Split): Agrupe a base por categoria.

Grupo Categoría A

Grupo Categoría B

Grupo Categoría C

[illegible]

A		
A		
A		
A		
A		

B		
B		
B		
B		
B		

C		
C		
C		
C		
C		

2. Focar: Isole apenas a coluna numérica `tempo_resolucao_horas`.

	tengo_resolucio o, Series
	2.5
	4.0
	3.2
	...

		tempe_resciu eoe_Sores
		5.1
		3.8
		4.9
		...

		tengo, resolva, cores
		1.8
		2.2
		1.9
		...

Cálculo da Média

3. Aplicar (Combine):

Calcule a média (mean) para cada grupo.

categoria	mean_tempe_resolucae_horas
A	3.23
A	3.23
B	4.60
C	1.97

Cálculo da Média

Regras de SLA

Prioridade	Tempo Limite
Crítica	4 horas
Alta	8 horas
Média	24 horas
Baixa	48 horas

A Missão Analítica

- [] Filtrar apenas chamados com status 'Resolvido'.
- [] Criar coluna limite_sla_horas.
- [] Criar validador booleano dentro_sla.
- [] Calcular percentual de sucesso/falha.
- [] Identificar categoria com a pior média de tempo.

Entregável Exigido: Código + conclusão gerencial (3-5 linhas) com métricas.

O Veredito

Base Analítica

16 chamados resolvidos analisados.

68,8%

Dentro do SLA (11/16)

31,2%

Fora do SLA (5/16)

O Gargalo

Gargalo: "Sistema Lento" possui a maior média de tempo (47,75 h).

Contexto: Esta média está fortemente distorcida pelo chamado atípico de 120 h.

Ação

Decisão Recomendada: Não altere processos ou contrate equipe ainda.

Investigue a causa-raiz desse chamado único (120 h) que está destruindo a métrica do SLA.

Anti-Patterns vs. Boas Práticas

	
 <code>df.shape()</code>	 <code>df.shape</code> (É um atributo contínuo, não uma função que se executa com parênteses).
 <code>cond1 and cond2</code>	 <code>(cond1) & (cond2)</code> (No Pandas, use operadores bitwise e isole com parênteses).
 <code>iloc['setor']</code>	 <code>iloc</code> exige posições estritamente numéricas (índices).
 <code>df.mean()</code> (aceitar cegamente)	 Verifique ausências e outliers com <code>describe()</code> antes de confiar na média.

Dica: O erro é um dado. Leia a mensagem do console, isole a linha que falhou e teste uma hipótese.

A Máscara: Filtra exclusivamente os chamados que voltaram a dar problema.

```
df.loc[  
    df['reaberto'] == 'Sim',  
    ['id_chamado', 'categoria', 'tempo_resolucao_horas']  
]
```

A Estrutura: O uso do `loc` garante o mapeamento cruzado entre a condição (linha) e o alvo (coluna).

A Estrutura: O uso do `loc` garante o mapeamento cruzado entre a condição (linha) e o alvo (coluna).

Próximo Passo: Transformar a tabela de síntese em narrativa visual. Até a próxima etapa do pipeline!